

December 7, 2022

Abstract

1 Conclusiones de artículos leídos e ideas a implementar

1.1 Estrategia para la selección del dataset y su procesado

The COVID-19 Open Research Dataset (CORD-19) presented by [Wang et al.(2020)Wang, Lo, Chandrasekhar, Reas, Yang, Eide, Funk, Kinney, Liu, Merrill, Mooney, Murdick, Rishi, Sheehan, Shen, Stilson, Wade, Wang, Wilhelm, Xie, Raymond, Weld, Etzioni, and Kohlmeier] has been used. CORD-19 contains a mixture of articles and preprints on COVID-19 and similar past coronaviruses like SARS and MERS. This resource was developed as an initiative to bring together the machine learning community with experts in the biomedical domain to identify effective treatments and management policies for COVID19. The CORD19 release used was the June 2, 2022 release. This version contains 401,214 documents from different years; the distribution of articles by year can be seen in Figure 1.




Figure 1: Distribution of papers in the corpus according to their publication date.

The information available for each article is as follows: title, authors, abstract, text, bibliographic entries, internal references (tables, figures or elements within the article with their respective title) and acknowledgements. In addition to this information, the following metadata is also available for each paper: the source from which it originates, its doi, the license of use, its date of publication and the journal in which was published.

Data preprocessing is one of the most critical processes when generating topic models. Is important to remove as much noise as possible while keeping the relevant terms. The more words that are removed, the faster, more efficient and more correct the models will be. For this reason, inspired by the guidelines given by [Maier et al.(2018)Maier, Waldherr, Miltner, Wiedemann, Niekler, Keinert, Pfetsch, Heyer, Reber, Häussler, Schmid-Petri, and Adam], these steps have been followed for the text preprocessing:

1. Due to the available resources and the large number of articles, it has been decided to work only with the abstracts of the articles. In this way, the computational cost of this phase was reduced. Considering the small number of articles that did not have abstracts, it was decided to discard them and not take them into account. In addition, there are papers in the corpus with publication dates later than the corpus version. Given the distortion that these articles can generate in the models, it has been decided not to take them into account. Thus, only previously published articles are used.
2. The corpus contains articles in several languages. The main language is English, so it was decided to filter the articles to use only those written in English. The *Langdetect* package was used to identify the language of the texts.
3. The text has been lowercased in order to group terms by character and not by their format. Observing the content of the abstracts, some DOI links have been found, therefore, and before carrying out the following steps, all the links have been deleted.
4. All stopwords present in the texts have been removed. The list of stopwords has been extracted from the repository *stopwords-iso*¹. In this repository, stopwords from different sources have been collected in order to create a list as extensive as possible.
5. Punctuation characters and all numbers have been removed. For punctuation characters, the list provided by the python package *String* has been used. However, due to the particularity of healthcare texts, single hyphens have not been removed.
6. A minimum word size criteria has been defined in order to eliminate acronyms and abbreviations which are difficult to interpret and use out of context. To this end, the decision has been taken to eliminate all words with less than 4 letters.
7. The remaining words after the previous steps are lemmatized. It has been decided to use lemmatization and not stemming because in this way, the

¹<https://github.com/stopwords-iso/stopwords-iso>

final result is more easily interpretable. The *WordNetLemmatizer* from the *Nltk* package has been used for this task.

8. Due to the size of the corpus, it has been assumed that, on the one hand, there will be words that, due to their high frequency in the documents, are common in the corpus and do not provide any significant value to the topics. On the other hand, there will be words that, due to their low frequency in the documents, are irrelevant. For this reason, pruning parameters of the maximum frequency of 80% and minimum frequency of 0.1% have been established. The pruning is performed based on the frequency of a term relative to the volume of all the words in the corpus. This task has been carried out using the *CountVectorizer* of the *Sklearn* package.
9. Similar to the minimum word size criteria, a minimum text size criterion has been established. The objective is to filter out all texts that have a number of words below a threshold, in order to filter out texts of a very general nature, full of stopwords, common words in the corpus, acronyms, etc. For this project a minimum text size of 5 words has been established.

After applying the preprocessing steps to the 401,214 papers in the corpus, only 245,476 were usable. The majority were discarded because they did not satisfy the minimum text size requirement after processing. The rest were excluded because they had no abstract or they are written in other language. In the end, preprocessing eliminates many terms, and several documents do not keep the defined minimum size required.

This task took 5 days, 17 hours and 45 minutes to complete with 160GB of RAM allocated. The distribution of the articles by date can be seen in image 1. In this image, it can be seen how 88% of the papers belong to the period 2020-2022. This may affect the construction of the topics.

In order to measure the impact of SARS-CoV-2 on the coronavirus literature, it is necessary to know which events and drugs are related to it. The drugs that appear on the living guidelines for COVID-19 set by WHO² will be used. This list contains recommendations for the use or non-use of different drugs and treatments. From this list we will take the different SARS-CoV-2 related drugs which will be used in the evaluation of the models.

We collected the context-stopwords in a resource available from Zenodo³. Some of the context-stopwords appear in the living guidelines for COVID-19 set by WHO. An example of this are the following words:

- The drug *nirmatrelvir-ritonavir*. It appears nine times in the corpus documents. On April 22, 2022, WHO strongly recommended the use of this drug in patients with a non-severe disease with an increased risk of hospitalization⁴. This word, which is important in this paper, has been removed because of its low appearance in the corpus. Perhaps, in future versions of the corpus, this word will appear more times and will not be removed.
- Elements related to *remdesivir*. On November 20, 2020, the WHO launches a conditional recommendation for the use of *remdesivir* in patients with

²<https://www.who.int/publications/i/item/WHO-2019-nCoV-therapeutics-2022.4>

³<https://doi.org/10.5281/zenodo.7129601>

⁴<https://app.magicapp.org/#/guideline/nBkO1E/rec/LwrMyv>

non-severe COVID-19 with increased risk of hospitalization⁵. Although the list of filtered words does not include *remdesivir* on its own, there are compound words with this term. In the word list, there are 40 terms with the word *remdesivir*. From all of them, the most repeated word is *remdesivir-tp*, a variation of *remdesivir* that appears 15 times in the corpus documents.

- The drug *molnupiravir*. On March 3, 2022, the WHO issued a conditional recommendation for the use of this drug in patients with non-severe COVID-19 at increased risk of hospitalization (excluding pregnant or breastfeeding women and children)⁶. This drug is listed because it appears only 87 times in the corpus documents. However, it is possible that in future versions of the corpus this word will be dropped from the list if it appears in more papers.

There are probably more terms in this list with an impact on this work. The problem is that the list is composed of 362,406 terms, which makes it difficult to analyze and evaluate the impact on the work.

⁵<https://app.magicapp.org/#/guideline/nBkO1E/rec/nBMO8R>

⁶<https://app.magicapp.org/#/guideline/nBkO1E/rec/E85WNb>

1.2 Estrategia de selección de modelos

El nivel de detalle de los tópicos probabilísticos creados usando modelos de tópicos dinámicos sobre el mismo corpus de publicaciones científicas del coronavirus, varía de acuerdo al algoritmo empleado. Los modelos de tópicos dinámicos identificados en el estado de la cuestión que se compararán son: BERTopic, DTM, D-ETM.

Para evaluar un modelo de tópicos dinámicos generado sobre un corpus de artículos científicos desbalanceado hay que evaluar la calidad de los tópicos generados durante varios espacios temporales. De esta forma, se analiza que los tópicos representan a la mayoría de artículos y no solo un determinado grupo. Para esto, hemos observado la coherencia de los tópicos generados en los últimos 5 años, para así, conocer si su evolución es homogénea y estable. Así, sabremos si los modelos generan tópicos que evolucionan progresivamente y representan correctamente la colección de textos. Para elegir al mejor nos basaremos concretamente en las métricas CV y UMass (interpretabilidad y especificidad respectivamente).

1.3 Análisis del modelo generado

Cada tópico representa un concepto específico. Este, está definido por las 15 palabras con mayor probabilidad para ese tópico. Para etiquetar los diferentes conceptos, hemos decidido tomar las palabras que han sido la top1 del tópico en cualquiera de los espacios temporales. Como el modelo óptimo de tópicos identifica conceptos independientes, no puede haber un tópico que contenga la misma etiqueta que otro.

Mediante un estudio superficial de las etiquetas generadas, se ha observado que muchas palabras son tendencias. Que los conceptos estén etiquetados por palabras que han sido tendencia no es representativo, ya que un concepto cambia en el tiempo pero mantiene la misma idea. Por ello, la estrategia de etiquetado ha sido levemente modificada.

Asumimos como ruido o tendencia aquellas palabras que aparecen en determinada fecha y desaparecen en otra. Con un gran impacto en el tópico en determinado punto. La duración de una palabra para ser considerada ruido o tendencia depende del tópico y del corpus. En este caso, nosotros definiremos las tendencias como aquellas palabras que son la top1 palabra del tópico en algún momento y no se mantienen en el top5 durante todos los momentos. Además, si un tópico no cumple con palabras que satisfagan este requisito, se asumirá que el tópico es volátil y no podrá ser utilizado para su estudio.

Esta estrategia nos permite definir los tópicos de manera más precisa. Para demostrar esto, hemos medido y comparado la distancia semántica de las etiquetas generadas para cada tópico. A menor cantidad de palabras, más específico es el tópico, siendo en el mejor de los casos definido por una etiqueta con una única palabra. Además, a parte de medir la precisión del tópico, también es importante medir su estabilidad. Para medir esto, hemos contabilizado la cantidad de tópicos volátiles respecto al total. De esta forma, podemos comparar los diferentes modelos creados y cual genera tópicos más estables.

1.4 Ilustración de resultados

Podemos utilizar el modelo word2vec generado para ilustrar la disposición espacial de algunas palabras. Además, junto con UMAP (técnica de reducción de dimensionalidad), podemos expresar esta disposición en un espacio 2D.

En primer lugar generar un punto para representar un tópico, este sería el centroide de las palabras que lo definen. En segundo lugar el centroide de su etiqueta.

2 Artículos

Se me han ocurrido dos ideas principales para escribir artículos, son trabajos diferentes NO excluyentes.

2.1 Estudio del corpus

Podríamos escribir un artículo sobre el estudio del corpus. Modelo con 100 tópicos y después de 200 tópicos para compararlos:

- Mostrar los tópicos generados y sus etiquetas, estables e inestables. Quizás mostrar algunas palabras de algún tópico.
- Generar centroides para las 15 top palabras del tópico.
- Generar centroides para las palabras de las etiquetas.
- Dibujar los diferentes centroides y comparar la diferencia que hay.
- Extraer los tópicos dominantes del corpus.
- *¿Analizar los artículos financiados? (estadísticas de cuantos son, en que tópicos se concentran, etc.)*
- Coger un tópico concreto y analizar su evolución con el centroide y su trayectoria espacial.

Comparar los centroides y apoyar la teoría de que independientemente del número de tópicos la relevancia se mantiene a lo largo del tiempo. Esto implica que los tópicos que tengan centroides cerca representan ideas similares. Buscar explicaciones con los centroides para la granularidad obtenida al establecer un mayor número de tópicos.

2.2 Estudio de los fármacos

Buscamos tratamientos y fármacos en los tópicos anteriores pero al ser tópicos con varias enfermedades nos hemos dado cuenta que la granularidad obtenida con la cantidad de tópicos no es suficiente para este objetivo. Por ello, vamos a generar modelos en el intervalo de fechas exclusivo del covid (diciembre 2019-actualidad).

De las 100 palabras únicas que aparecen en el top de los tópicos, comparo contra drugs4covid cuales son medicamentos y cuales enfermedades. Saco los fármacos y enfermedades que salen en varios tópicos (varios contextos) y analizo su tendencia para cada uno. (Idealmente de forma agregada)

3 Artículos leídos

Gran parte de los artículos son de autores chinos y tratan del análisis de opiniones. Muchos con financiación estatal china. Además, es un denominador común en las investigaciones aplicar estas técnicas sobre el texto recogido de diferentes redes sociales.

[Yao and Wang(2020)]: Estos autores presentan la idea de **cada tópico tiene una trayectoria definida** como el camino que atraviesa el centroide del tópico a través de los diferentes espacios temporales. Además, definen que un tópico es estático o dinámico, es decir si cambia mucho o poco en el tiempo (porque el cambio es inevitable), en base a la distancia que recorre el tópico. Fijan una distancia máxima por fecha que vale para establecer si un tópico cambia mucho o poco.

[Lee and Krumm(2011)]: La trayectoria espacial la definen estos autores (cita del anterior artículo).

[Alazba et al.(2022)Alazba, Abouhagar, Al-Harbi, Al-Jamimi, Sultan, and Al-Zaidy]: Este artículo no me ha gustado nada, parece muy sesgado, simple, los modelos han sido elegidos a dedo y hay muchas cosas hechas a mano. Sin embargo he encontrado algunas cosas interesantes.

- Definen el tópico trending o dominante como aquel que predomina en la mayoría de artículos. Es decir, teniendo la distribución de tópicos documentos extraen el tópico que predomina en cada documento, con esto cuentan cuál es el tópico más repetido y ése es.
- Definen los N tópicos más importantes del corpus como los N que más predominan (siguiendo el proceso anterior).
- Para etiquetar los tópicos utilizan el documento más relevante y las top 20 palabras y lo hacen a mano. Asignan nombre basándose en las palabras y lo confirman con el documento.
- Analizan la cantidad de artículos financiados y los tópicos más financiados.

3.1 Otros enfoques

[Churchill and Singh(2022)]: Estos autores presentaron un dynamic topic-noise discriminator. Proponen el Dynamic Noiseless Latent Dirichlet Allocation, adaptan el topic-noise model a un espacio temporal de las redes sociales, es una adaptación temporal del Noiseless Latent Dirichlet Allocation. Este enfoque no solo propone que un tópico evoluciona a lo largo del tiempo, sino que también asume que un tópico está formado por palabras y ruido. Creando una distribución de ruido. A los de este estudio D-ETM tampoco les genera tópicos de calidad. Estos analizan la evolución del tópico de la vacuna del coronavirus con el corpus del COVID-19 (NO DICE CUAL).

3.2 Colecciones de artículos

[Sleeman et al.(2021)Sleeman, Finin, and Halem]: Estos autores hacen un estudio muy parecido al que nosotros buscamos pero en otro contexto. Utilizan documentos técnicos sobre una colección de documentos de ciberseguridad. Además, presentan los documentos, los conceptos y los tópicos en gráficos de conocimiento

para ayudar a la integración y poder hacer consultas. “When we build topic models over time, topics evolve over time based on the documents in the collection at that time point. Our observation is as we increased the number of topics, we saw more granularity among topics. Topics represented more narrow mixtures. We also observed concepts that drop off of one topic and fall into another at various points in time”.

3.3 Social Media Data

[Golino et al.(2022)Golino, Christensen, Moulder, Kim, and Boker]: Estos autores analizan los mensajes publicados en redes sociales que instigaron a la opinión pública a desconfiar de los procesos electorales de EEUU en el año 2016. No se pueden extraer cosas muy diferentes a las de otros artículos pero me ha gustado el concepto de que hay cuestiones que influyen la opinión pública. Hacen un análisis de opinión que actualmente no nos interesa pero está bien saber que herramientas han utilizado y como, sobre todo porque los tweets no contienen mucho texto. De hecho, podemos analizar la largura media de un abstract para compararla con un tweet y explicar que puede haber modelos que trabajen mejor con volúmenes de datos de menor longitud. En la sección de análisis de datos de diferentes formas (citan algunos enfoques). Crea un modelo de 10 tópicos que es bastante gráfico.

[Ghoorchian and Sahlgren(2020)]: Estos autores crean una solución para aplicar DTM en textos cortos de redes sociales. En teoría utilizan grafos de conocimiento pero como por ahora esto no nos interesa no he profundizado. Sin embargo esta guay la definición que hacen de las técnicas de modelado de tópicos: the goal is to reduce the high-dimensional space of words into a significantly low-dimensional and semantically rich space of topics (citan un artículo).

[Tabassum et al.(2021)Tabassum, Gama, Azevedo, Teixeira, Martins, and Martins]: En este artículo usan los modelos de tópicos para extraer tópicos de los tweets. Sin embargo, los tópicos están definidos por los hashtags y los utilizan para definir los tópicos que se van a tratar.

References

- [Wang et al.(2020)Wang, Lo, Chandrasekhar, Reas, Yang, Eide, Funk, Kinney, Liu, Merrill, Mooney, Murdick, Lucy Lu Wang, Kyle Lo, Yoganand Chandrasekhar, Russell Reas, Jiangjiang Yang, Darrin Eide, Kathryn Funk, Rodney Michael Kinney, Ziyang Liu, William Cooper Merrill, Paul Mooney, Dewey A. Murdick, Devvret Rishi, Jerry Sheehan, Zhihong Shen, Brandon Stilson, Alex D Wade, Kuansan Wang, Christopher Wilhelm, Boya Xie, Douglas A. Raymond, Daniel S. Weld, Oren Etzioni, and Sebastian Kohlmeier. Cord-19: The covid-19 open research dataset. *ArXiv*, 2020.
- [Maier et al.(2018)Maier, Waldherr, Miltner, Wiedemann, Niekler, Keinert, Pfetsch, Heyer, Reber, Häussler, Daniel Maier, A. Waldherr, P. Miltner, G. Wiedemann, A. Niekler, A. Keinert, B. Pfetsch, G. Heyer, U. Reber, T. Häussler, H. Schmid-Petri, and S. Adam. Applying lda topic modeling in communication research: Toward a valid and reliable methodology. *Communication Methods and Measures*, 12(2-3):93–118, 2018. doi: 10.1080/19312458.2018.1430754.

- [Yao and Wang(2020)] Fang Yao and Yan Wang. Tracking urban geo-topics based on dynamic topic model. *Computers, Environment and Urban Systems*, 79:101419, 1 2020. ISSN 0198-9715. doi: 10.1016/J.COMPENVURBSYS.2019.101419.
- [Lee and Krumm(2011)] Wang-Chien Lee and John Krumm. Trajectory pre-processing, 2011.
- [Alazba et al.(2022)] Alazba, Abouhagar, Al-Harbi, Al-Jamimi, Sultan, and Al-Zaidy] Amal Alazba, Leina Abouhagar, Randah Al-Harbi, Hamdi A. Al-Jamimi, Abdullah Sultan, and Rabah A. Al-Zaidy. Detection of research trends using dynamic topic modeling. 2022. doi: 10.1109/CDMA54072.2022.00031.
- [Churchill and Singh(2022)] Rob Churchill and Lisa Singh. Dynamic topic-noise models for social media, 2022.
- [Sleeman et al.(2021)] Sleeman, Finin, and Halem] Jennifer Sleeman, Tim Finin, and Milton Halem. Understanding cybersecurity threat trends through dynamic topic modeling. *Frontiers in Big Data*, 4, 6 2021. ISSN 2624-909X. doi: 10.3389/fdata.2021.601529.
- [Golino et al.(2022)] Golino, Christensen, Moulder, Kim, and Boker] Hudson Golino, Alexander P. Christensen, Robert Moulder, Seohyun Kim, and Steven M. Boker. Modeling latent topics in social media using dynamic exploratory graph analysis: The case of the right-wing and left-wing trolls in the 2016 us elections. *Psychometrika*, 87:156–187, 3 2022. ISSN 0033-3123. doi: 10.1007/s11336-021-09820-y.
- [Ghoorchian and Sahlgren(2020)] Kambiz Ghoorchian and Magnus Sahlgren. Gdtm: Graph-based dynamic topic models. *Progress in Artificial Intelligence*, 9(3):195–207, Sep 2020. ISSN 2192-6360. doi: 10.1007/s13748-020-00206-2. URL <https://doi.org/10.1007/s13748-020-00206-2>.
- [Tabassum et al.(2021)] Tabassum, Gama, Azevedo, Teixeira, Martins, and Martins] Shazia Tabassum, João Gama, Paulo Azevedo, Luis Teixeira, Carlos Martins, and Andre Martins. Dynamic topic modeling using social network analytics, 2021.